



APPLIED DATA SCIENCE CAPSTONE

SpaceX Falcon 9 First Stage Landing Prediction

Usando ciencia de datos y machine learning para predecir el aterrizaje exitoso de la primera etapa del cohete Falcon 9

Autor: [Tu nombre]

Fecha: Julio 2026

Agenda

01

Resumen ejecutivo

Objetivo del proyecto y hallazgos clave

02

Introducción

Contexto de negocio y preguntas de investigación

03

Metodología

Flujo de trabajo end-to-end de ciencia de datos

04

Recolección de datos

API de SpaceX y web scraping de Wikipedia

05

Wrangling y EDA con SQL

Limpieza, etiquetado y consultas exploratorias

06

EDA con visualización

Relaciones entre variables clave

07

Analítica visual interactiva

Mapas Folium y dashboard Plotly Dash

08

Análisis predictivo

Modelos de clasificación y comparación

09

Conclusiones

Resultados y recomendaciones

Resumen ejecutivo

SpaceX reduce el costo de sus lanzamientos reutilizando la primera etapa del cohete Falcon 9. Este proyecto recopila, limpia y analiza datos históricos de lanzamientos para predecir si la primera etapa aterrizará con éxito, información clave para estimar el costo de un lanzamiento.



Datos

Se combinaron datos de la API pública de SpaceX y web scraping de Wikipedia: 90+ lanzamientos con 17 variables.



Preparación

Se creó la etiqueta binaria 'Class' de éxito/fallo del aterrizaje. Tasa de éxito global: 66.7%.



EDA

El éxito del aterrizaje mejora con el número de vuelo, el tipo de órbita (ISS, LEO, VLEO) y el año.



Modelado

4 modelos de clasificación comparados con GridSearchCV. El árbol de decisión logró la mejor validación cruzada (87.7%).

Conclusión clave: el modelo predictivo alcanza ~83% de exactitud en datos de prueba, demostrando que es posible anticipar el éxito del aterrizaje a partir de variables operativas conocidas antes del lanzamiento.

Introducción

Contexto de negocio

- SpaceX anuncia lanzamientos del Falcon 9 desde \$62 millones, frente a los más de \$165 millones de otros proveedores.
- Gran parte del ahorro proviene de la reutilización de la primera etapa del cohete.
- Si se puede predecir si la primera etapa aterrizará con éxito, se puede estimar el costo de un lanzamiento.
- Esta información es valiosa para que otra compañía compita con SpaceX al ofertar por el lanzamiento de un cohete.

Preguntas de investigación

- ¿Qué variables (payload, órbita, sitio de lanzamiento, año) influyen más en el éxito del aterrizaje?
- ¿Qué algoritmo de clasificación predice mejor el resultado del aterrizaje?



Falcon 9

\$62M

costo anunciado por lanzamiento SpaceX

\$165M+

costo típico de la competencia

66.7%

tasa de éxito de aterrizaje en el dataset

90+

lanzamientos históricos analizados

Metodología

Flujo de trabajo completo de ciencia de datos, de la recolección al modelo predictivo

1



Recolección de datos

API pública de SpaceX + web scraping de Wikipedia

2



Wrangling

Limpieza, valores nulos y etiqueta de éxito (Class)

3



EDA con SQL

Consultas SQL sobre la base SQLite del dataset

4



EDA visual

Matplotlib / Seaborn para patrones y correlaciones

5



Analítica geoespacial

Mapas interactivos con Folium

6



Dashboard

Panel interactivo con Plotly Dash

7



Modelado predictivo

Clasificación con GridSearchCV (4 algoritmos)

8



Evaluación

Comparación de exactitud y matriz de confusión

Recolección de datos: API de SpaceX

Se realizaron peticiones GET al endpoint REST v4 de SpaceX (api.spacexdata.com) y se normalizó la respuesta JSON con `pandas.json_normalize()`.

1

GET /launches/past

Solicitud a la API REST v4 de SpaceX

2

json_normalize()

Conversión de JSON anidado a DataFrame

3

Funciones auxiliares

`getBoosterVersion`, `getLaunchSite`,
`getPayloadData`, `getCoreData`

4

Filtrado Falcon 9

Se excluyen lanzamientos de Falcon 1

Variables extraídas de la API

FlightNumber

Date

BoosterVersion

PayloadMass

Orbit

LaunchSite

Outcome

Flights

GridFins

Reused

Legs

LandingPad

Block

ReusedCount

Serial



Resultado

200

código de estado HTTP de la respuesta

Dataset limpio con lanzamientos Falcon 9, listo para wrangling.

Recolección de datos: Web Scraping

Se extrajo la tabla histórica de lanzamientos Falcon 9 y Falcon Heavy desde Wikipedia usando BeautifulSoup, con una versión estática de la página para garantizar resultados consistentes.

- `requests.get()` sobre una revisión fija de la página de Wikipedia (`oldid`).
- `BeautifulSoup(response.text, 'html.parser')` para parsear el HTML.
- Se localiza la tabla objetivo entre las `<table>` de la página (`html_tables[2]`).
- `extract_column_from_header()` limpia los nombres de columna.
- Se recorren las filas `<tr>` para poblar un diccionario y construir el DataFrame final.

Columnas extraídas: Flight No., Date and time, Launch site, Payload, Payload mass, Orbit, Customer, Launch outcome, Booster version, Booster landing.



Fuente de datos


*List of Falcon 9 and Falcon Heavy launches — Wikipedia
(snapshot 9 junio 2021)*

```
static_url = (  
    'https://en.wikipedia.org/w/index.php'  
    '?title=List_of_Falcon_9_and_'  
    'Falcon_Heavy_launches&oldid=...')  
  
response = requests.get(static_url)  
soup = BeautifulSoup(  
    response.text, 'html.parser')  
  
html_tables = soup.find_all('table')  
first_launch_table = html_tables[2]
```


Wrangling de datos

A partir del resultado del aterrizaje (Outcome) se construyó la variable objetivo binaria Class: 1 si la primera etapa aterrizó con éxito, 0 en caso contrario.

Lanzamientos por sitio



Distribución por tipo de órbita (top 5)



Tasa de éxito global

66.7%

```
df['Class'].mean() = 0.667
```

60 de 90 lanzamientos analizados aterrizaron con éxito la primera etapa.

EDA con SQL

Se cargó el dataset en SQLite y se ejecutaron consultas SQL para responder preguntas de negocio clave.

Sitios de lanzamiento únicos

```
SELECT DISTINCT Launch_Site
```

CCAFS LC-40, VAFB SLC-4E, KSC LC-39A,
CCAFS SLC-40

Payload promedio F9 v1.1

```
AVG(PAYLOAD_MASS__KG_)
```

2,928.4 kg

Primer aterrizaje exitoso en tierra

```
MIN(Date) WHERE Landing_Outcome = 'Success  
(ground pad) '
```

22 diciembre 2015

Boosters con éxito en dron-ship (4–6 t)

```
WHERE Landing_Outcome LIKE 'Success (drone  
ship) '
```

F9 FT B1022, B1026, B1021.2, B1031.2

Resultados de misión

```
GROUP BY Mission_Outcome
```

98 de 101 registros con éxito (~97%)


Boosters con carga máxima

```
WHERE PAYLOAD = MAX(PAYLOAD)
```

Serie F9 B5 (10 boosters distintos)

EDA con SQL: outcomes de aterrizaje (2010–2017)


Ranking de los distintos resultados de aterrizaje registrados entre el 4 de junio de 2010 y el 20 de marzo de 2017:



Insight: en los primeros años el número de intentos sin recuperación ("No attempt") aún dominaba; los aterrizajes exitosos en dron-ship y en tierra empiezan a consolidarse a partir de 2015-2016.


EDA con visualización (I)

Número de vuelo vs. masa de carga (Payload)



El éxito (naranja) aumenta con vuelos más recientes y no muestra un límite claro por masa de carga.


Número de vuelo por sitio de lanzamiento



KSC LC-39A concentra los vuelos más recientes; los primeros vuelos partieron desde CCAFS SLC 40.


EDA con visualización (II)

Masa de carga vs. sitio de lanzamiento



VAFB SLC-4E no ha lanzado cargas pesadas (>10,000 kg); CCAFS y KSC sí manejan cargas mayores.


Tasa de éxito por tipo de órbita



ES-L1, GEO, HEO, SSO alcanzan 100% de éxito; GTO presenta la tasa más baja (~52%).


EDA con visualización (III)

N.º de vuelo vs. órbita




En LEO el éxito crece con el número de vuelos; en GTO no hay relación clara.

Masa de carga vs. órbita



Con cargas pesadas, Polar, LEO e ISS muestran más éxitos; en GTO se mezclan ambos resultados.

Tendencia anual de éxito



La tasa de éxito crece de forma sostenida entre 2013 y 2020.

Analítica visual interactiva: mapas con Folium

Se construyó un mapa interactivo para analizar la ubicación de los sitios de lanzamiento y su proximidad a costas, ciudades, carreteras y vías férreas.



CCAFS LC-40 / SLC-40

28.56° N, -80.58° O

Florida — Cabo Cañaveral



KSC LC-39A

28.61° N, -80.60° O

Florida — Kennedy Space Center



VAFB SLC-4E

34.63° N, -120.61° O

California — Base Vandenberg

Hallazgo clave: todos los sitios están muy cerca de la línea de costa (para el descenso del cohete sobre el océano) y relativamente lejos de zonas urbanas densas, por seguridad.

Funcionalidades del mapa Folium



Marcadores por sitio

folium.Circle + folium.Marker con etiqueta en cada sitio de lanzamiento.



Clúster de resultados

MarkerCluster colorea cada lanzamiento: verde = éxito, rojo = fallo.



Posición del cursor

Plugin MousePosition para leer coordenadas al pasar el mouse.




Líneas de distancia

PolyLine + distancia Haversine entre el sitio y costa, ciudad o vía férrea cercana.

Analítica visual interactiva: dashboard Plotly Dash

Se desarrolló un dashboard web interactivo (spacex-dash-app.py) para explorar los datos de lanzamiento de forma dinámica.



Componentes interactivos

- **Dropdown de sitio** Filtra todos los gráficos por sitio de lanzamiento o 'All Sites'.
- **Gráfico circular (pie)** Proporción de lanzamientos exitosos por sitio o resultado éxito/fallo.
- **Slider de payload** Rango de masa de carga (0–10,000 kg) para acotar el análisis.
- **Scatter payload vs. clase** Relación entre masa de carga, versión del booster y resultado.

Análisis predictivo: metodología

1

Variable objetivo (Y)

```
Y = data['Class'].to_numpy()
```

2

Estandarización (X)

```
StandardScaler().fit(X).transform(X)
```

3

Train / Test split

```
test_size = 0.2, random_state = 2 → 18 muestras de prueba
```

4

GridSearchCV (cv = 10)

```
Búsqueda de hiperparámetros para cada modelo
```

Modelos comparados

Regresión Logística

SVM

Árbol de Decisión

K-Nearest Neighbors



Hiperparámetros explorados

Log. Regression

```
C: [0.01, 0.1, 1] · penalty: l2 · solver: lbfgs
```

SVM

```
kernel: linear/rbf/poly/sigmoid · C, gamma: logspace(-3, 3, 5)
```

Árbol de Decisión


```
criterion: gini/entropy · max_depth: 2-18 · splitter: best/random
```

KNN

```
n_neighbors: 1-10 · algorithm: auto/ball_tree/kd_tree/brute · p: 1,2
```

Análisis predictivo: comparación de modelos

Exactitud de validación cruzada (best_score_, cv=10)



Exactitud en datos de prueba (test set, n=18)

83.3%

Los cuatro modelos empataron en exactitud sobre el conjunto de prueba (18 muestras): Regresión Logística, SVM, Árbol de Decisión y KNN.



Mejor modelo

Árbol de Decisión

87.7% de exactitud en validación cruzada — el mejor desempeño entre los 4 modelos evaluados.

Mejores hiperparámetros:

```
criterion: entropy · max_depth: 2  
max_features: sqrt · min_samples_leaf: 2  
min_samples_split: 10 · splitter: random
```

Nota: en el conjunto de prueba (muy pequeño, n=18) los 4 modelos empatan en 83.3%; la validación cruzada es más representativa del desempeño real.

Análisis predictivo: matriz de confusión

Matriz de confusión sobre el conjunto de prueba (18 lanzamientos) para el modelo de Regresión Logística.

Real:	Predicción	
	No aterrizó	Aterrizó
No aterrizó	3 Verdadero Negativo	3 Falso Positivo
Aterrizó	0 Falso Negativo	12 Verdadero Positivo

Lectura de resultados

12 aterrizajes exitosos correctamente identificados por el modelo. **3 aterrizajes fallidos** correctamente identificados. **3 falsos positivos:** el modelo predijo aterrizaje exitoso cuando en realidad falló. **0 falsos negativos:** el modelo no dejó pasar ningún aterrizaje exitoso.

Principal área de mejora: reducir los falsos positivos, que sobreestiman los aterrizajes exitosos.

Conclusiones



El éxito de aterrizaje mejora con el tiempo

La tasa de éxito global es 66.7% y crece de forma sostenida entre 2013 y 2020, mostrando el aprendizaje operativo de SpaceX.



La órbita y el sitio de lanzamiento importan

Órbitas como ES-L1, GEO, HEO y SSO alcanzan 100% de éxito; GTO es la más desafiante (~52%). KSC LC-39A concentra los lanzamientos más recientes.



Los modelos predicen con buena precisión

El Árbol de Decisión logra 87.7% de exactitud en validación cruzada; los 4 modelos alcanzan 83.3% en el conjunto de prueba.



Los falsos positivos son la principal debilidad

La matriz de confusión muestra 0 falsos negativos, pero algunos falsos positivos, útil para calibrar el riesgo en la toma de decisiones.



Gracias

Applied Data Science Capstone · SpaceX Falcon 9 Landing Prediction

Repositorio de GitHub : <https://github.com/Nataliaplm/Data-science-capstone-ibm>